

VISUALITZACIÓ DE DADES (EE – UAB) - CURS 2025-26

PROJECTE SPOTIFY FEATURES

GRUP 03

ACTA DE REUNIÓ No. 3

19 MAIG 2026

ASSISTENTS: Laia Alcalde, Laia Camara, Cristina Huanca, Elena Gutiérrez, Iker Bolancé i Alex Mayer

HORA D'INICI: 15:00

LLOC: Aula Q4/1009

1. Discussió.

Des de l'última acta s'ha completat tota la fase d'anàlisi prèvia al frontend i s'ha començat el disseny del dashboard. La discussió s'ha centrat principalment en tres punts:

En primer lloc, s'ha tancat l'EDA i la reducció de dimensionalitat. S'han generat les visualitzacions necessàries per justificar quines features es mantenen i quines són redundants. La correlació alta entre energy-loudness (+0.83) i energy-acousticness (-0.73) confirma que aquestes variables actuen de forma redundant abans del PCA.

En segon lloc, s'han analitzat els resultats del clustering. El model K-Means aplicat sobre les features acústiques normalitzades dona lloc a tres clústers interpretables: Spoken / Live, Ambient / Instrumental i Mainstream Pop / Rock. Els centroides es guarden a `config/cluster_profiles.json` perquè les etiquetes humanes no quedin codificades directament al frontend.

Finalment, s'ha definit l'arquitectura del dashboard. El dashboard ja existeix com a HTML autònom: `design/Featurefy Dashboard (standalone).html`, i està preparat per connectar-se via API amb els scripts de Python. Les dades, com les coordenades PCA/t-SNE, els perfils de clúster i els presets de playlist, es serviran des dels outputs ja generats a `outputs/{eda,pca,tsne,clustering}/*.csv` i des de `config/*.json`, evitant fer hardcoding dins del fitxer HTML.

2. Acords.

S'ha acordat donar per tancada la fase d'EDA, PCA, t-SNE i clustering com a anàlisi base del dashboard. Tots els outputs queden versionats dins la carpeta `outputs/`.

També s'ha acordat utilitzar les set features acústiques següents per al clustering i per als sliders de la playlist personalitzable: energy, acousticness, speechiness, liveness, instrumentality, popularity i danceability. La variable loudness queda fora per la seva redundància amb energy.

Les etiquetes dels clústers, és a dir, Spoken / Live, Ambient / Instrumental i Mainstream Pop / Rock, així com els presets de playlist, es mantindran com a configuració externa mitjançant els fitxers `config/cluster_profiles.json` i `config/playlist_presets.json`. D'aquesta manera, es podran regenerar fàcilment si es torna a entrenar el model K-Means.

Finalment, s'ha acordat que la propera fase serà connectar el dashboard standalone amb una capa API que exposi els CSV i JSON ja existents, en lloc de duplicar dades directament dins l'HTML.

Tasca	Descripció	Responsable	Participants (%)	Durada (setmanes)	Grau Finalització
Tasca 1	EDA visual complet	Laia C	Laia C (50%), Laia A (50%)	1	100%
Tasca 2	PCA + t-SNE	Iker	Iker(50%) Alex(50%)	1	100%
Tasca 3	Clustering K-Means multi-k	Elena	Elena(70%) Cris(30%)	1	100%
Tasca 4	Xarxa de correlació amb Plotly	Cris	Cris (70%) Laia A (30%)	1	100%
Tasca 5	Dashboard v1 Featurefy	Laia A	Laia A (50%), Cris (50%)	2	80%
Tasca 6	Connexió dashboard ↔ API scripts	Alex	Alex (50%) Elena (50%)	2	10%
GRAU DE MADURESA:					80%

3. Desenvolupament del projecte

3.1. Tasca 1

S'han generat set visualitzacions noves que abans no existien:

- eda_histograms.png: distribució i KDE de les 11 *features* numèriques, útil per detectar asimetries, bimodalitats i outliers.
- eda_boxplots_genre.png: boxplots de energy, danceability, valence i popularity separats per gènere.
- eda_correlation_heatmap.png: mapa de calor de la correlació de Pearson entre *features*.
- eda_scatter_high_corr.png: gràfics de dispersió de les parelles amb correlació alta, com energy–loudness i energy–acousticness, confirmant visualment la redundància.
- eda_scatter_popularity.png: relació de popularity amb danceability, energy i valence.
- eda_violin_genre.png: violin plots per gènere, que permeten detectar bimodalitats que el boxplot pot amagar.
- eda_correlation_network.png: versió en forma de xarxa del heatmap, on els nodes representen *features* i les arestes representen correlacions.

A més, es genera el fitxer `outputs/eda/genre_profiles.csv`, que conté la mitjana de cada *feature* per gènere. Aquest fitxer servirà com a input directe per al radar del dashboard.

3.2. Tasca 2

Fitxers principals: `pca_analysis.py` i `tsne_analysis.py`

Pel que fa al PCA, s'han generat les següents figures dins `outputs/pca/figures/`:

- `pca_scree.png`: gràfic de variància explicada acumulada de PC1 a PC11.
- `pca_scatter_genre.png`: projecció PC1–PC2icolorida per gènere.
- `pca_biplot.png`: scatter PC1–PC2 amb fletxes de loadings.

Pel que fa al t-SNE, s'han generat les figures següents dins `outputs/tsne/figures/`:

- `tsne_genre.png`
- `tsne_popularity.png`

Aquestes visualitzacions s'han calculat sobre una mostra de 10.000 cançons per fer el procés computacionalment viable.

Les coordenades resultants es guarden als fitxers `pca_coords.csv` i `tsne_coords.csv`, de manera que el dashboard les pugui consumir directament sense haver de recalculer res al navegador.

3.3. Tasca 3

S'ha implementat un clustering multi-k amb valors de $k = 2$ fins a $k = 12$. Això permetrà oferir un slider interactiu al dashboard perquè l'usuari pugui escollir el nivell de granularitat del clustering.

Els outputs generats són:

- `clustering_elbow.png`
- `clustering_silhouette.png`
- `clustering_tsne.png`
- `cluster_labels.csv`
- `cluster_profiles.csv`
- `cluster_multi_k.csv`

El fitxer `cluster_labels.csv` conté el clúster assignat a cada cançó. El fitxer `cluster_profiles.csv` conté els centroides dels clústers, i `cluster_multi_k.csv` guarda les assignacions per a tots els valors de k disponibles al slider.

Els tres clústers principals s'han interpretat manualment i s'han guardat a `config/cluster_profiles.json` amb les etiquetes següents:

- Spoken / Live
- Ambient / Instrumental
- Mainstream Pop / Rock

3.4. Tasca 4

S'ha creat un nou script que genera una xarxa interactiva de correlacions de Pearson entre *features* en format Plotly. Aquesta visualització està pensada per integrar-se dins la secció /05 del dashboard.

En aquesta xarxa, els nodes representen les *features* i les arestes representen les correlacions entre elles. El gruix de cada aresta indica la força de la correlació, mentre que el color indica el signe de la correlació.

3.5. Tasca 5

Actualment ja es disposa d'una primera versió del dashboard en tres fitxers:

- Featurefy Dashboard.html: versió de treball.

El dashboard inclou les seccions previstes a l'Acta nº 2:


- Builder: playlist personalitzable amb sliders de pes per *feature*.
- Space: projecció PCA/t-SNE acolorida per clúster.
- Radar de gèneres.
- Graf de correlació.
- Vinil de visualització de gèneres.

3.6. Tasca 6

Estat: **pendent**

Següent fita del projecte

El dashboard ja està preparat per connectar-se via API amb els scripts de Python. L'arquitectura prevista és la següent:



Aquesta estructura permetrà que, si es regeneren els clústers o el t-SNE, només calgui tornar a executar els scripts. El dashboard s'actualitzarà automàticament sense necessitat de modificar manualment el fitxer HTML.

S'acaba la reunió a les 17:00.

Signatures:

A stylized signature consisting of a large, open 'G' shape with a horizontal line extending to the right.

Elena Gutiérrez del Burgo

A signature featuring a large, circular loop on the left, followed by a series of smaller, connected loops and a horizontal line extending to the right.

Cristina Huanca

A signature with a large, open 'C' shape and a horizontal line extending to the right.

Laia Cámara

A signature with the word 'LAIA' written in a stylized, outlined font, followed by a horizontal line extending to the right.

Laia Alcalde Maria

A signature with a large, open 'A' shape and a horizontal line extending to the right.

Alex Stefan Mayer

A signature consisting of a large, cloud-like or bubble-like shape.

Iker Bolancé Gómez