

VISUALITZACIÓ DE DADES (EE – UAB) - CURS 2024-25

PROJECTE SPOTIFY FEATURES

GRUP 03

ACTA DE REUNIÓ No. 2

28 ABRIL 2025

ASSISTENTS: Laia Alcalde, Laia Camara, Cristina Huanca, Elena Gutiérrez, Iker Bolancé i Alex Mayer

HORA D'INICI: 15:00

LLOC: Aula Q4/1009

1. Discussió.

Durant la discussió s'ha valorat que el dataset és adequat perquè combina informació identificativa de les cançons (genre, artist_name, track_name, track_id) amb descriptors acústics com danceability, energy, tempo, valence, acousticness, instrumentality, liveness, loudness i speechiness. Això permet formular hipòtesis sobre la relació entre els gèneres musicals i les característiques sonores de les cançons.

Després de parlar amb la professora, el grup té més clar que el projecte no s'ha de limitar a aplicar mètodes automàticament, sinó que cal justificar bé les decisions preses. En concret, cal explicar l'objectiu final de l'anàlisi, argumentar per què s'utilitzen unes features i no unes altres, i tenir cura amb decisions de preprocessament que poden afectar els resultats, com l'eliminació de duplicats o el tractament de valors extrems.

També s'ha comentat que una mateixa cançó pot aparèixer associada a més d'un gènere. Per tant, eliminar duplicats únicament per track_id podria fer perdre informació rellevant. Aquesta qüestió s'ha identificat com un punt metodològic important que caldrà discutir abans de fixar definitivament el dataset net.

3. Acords.

S'ha acordat utilitzar el dataset Spotify Features com a base del projecte. El fitxer original es mantindrà sense modificar a data/raw/SpotifyFeatures.csv, i les transformacions es faran en un fitxer processat separat.

S'ha acordat formular el projecte al voltant de la idea d'analitzar si les característiques acústiques de les cançons permeten observar patrons, agrupacions o diferències entre gèneres musicals.

S'ha acordat que el gènere musical s'utilitzarà principalment com a variable d'interpretació i comparació, però que caldrà revisar amb cura els casos en què una mateixa cançó apareix en més d'un gènere.

S'ha acordat que el dashboard final d'entrega inclourà, a més dels gràfics analítics, un generador d'una llista personalitzable de cançons modificant el percentatge o pes de les diferents features musicals i playlists inspirades en Spotify.

Tasca	Descripció	Responsable	Participants (%)	Durada (setmanes)	Grau Finalització
Tasca 1	Transformació dataset	Laia C	Laia C (30%), Iker (30%)	1	70%
Tasca 2	Discussió objectiu final	Elena	Elena (30%), Laia C (30%)	2	60%
Tasca 3	Recerca estudis científics	Alex	Cris (40%), Alex (20%)	2	60%
Tasca 4	Discussió features	Laia A	Cris (30%), Laia A (30%)	3	30%
GRAU DE MADURESA:					60%

3. Desenvolupament del projecte

3.1. Tasca 1

La primera tasca consisteix a transformar el dataset original de Spotify Features en una versió neta i preparada per a l'anàlisi. El fitxer original es conserva sense modificar a data/raw/SpotifyFeatures.csv, mentre que el resultat del procés es genera a data/processed/spotify_clean.csv.

Durant aquesta transformació es fan diversos passos:

Inspecció inicial del dataset: nombre de files i columnes, tipus de dades, valors nuls, duplicats i distribució de cançons per gènere.

Tractament de valors nuls, imputant la mitjana en variables numèriques i el mode en variables categòriques.

Conversió de duration_ms a duration_min, per treballar amb una unitat més interpretable.

Selecció de les columnes informatives i de les variables numèriques que s'utilitzaran en les fases posteriors.

També cal deixar constància de les decisions metodològiques pendents o crítiques. En particular, la deduplicació per track_id s'ha de revisar amb cura, perquè una mateixa cançó pot aparèixer associada a més d'un gènere. Eliminar duplicats mantenint només la primera aparició pot fer perdre informació vàlida sobre la relació entre cançons i gèneres. A més, hi ha cançons amb durades molt llargues, fet que pot afectar els mètodes basats en distàncies o variància; per això cal decidir si aquestes durades es mantenen, es filtren o es tracten com a outliers.

3.2. Tasca 2

Una altra tasca important és definir amb precisió quin és l'objectiu final del projecte. El dataset permet diverses aproximacions: exploració descriptiva, reducció de dimensionalitat, visualització de patrons musicals, agrupació de cançons semblants o anàlisi de la relació entre gèneres i característiques acústiques.

Per a l'informe, cal concretar quina pregunta volem respondre. Per exemple:

Es poden agrupar les cançons segons les seves característiques musicals independentment del gènere declarat?

Els gèneres musicals tenen perfils acústics diferenciables?

Quines variables expliquen millor la separació entre grups de cançons?

Les tècniques de reducció de dimensionalitat permeten visualitzar estructures rellevants dins del dataset?

Aquesta discussió és necessària perquè condiciona totes les decisions posteriors: quines features es mantenen, com es tracten els duplicats, si el gènere s'utilitza com a etiqueta d'interpretació o com a variable de comparació, i quins mètodes d'anàlisi són més adequats.

3.3. Tasca 3

També cal fer una recerca bibliogràfica sobre estudis científics relacionats amb l'anàlisi de música mitjançant característiques acústiques. Aquesta recerca ha de servir per justificar les decisions del projecte i connectar el nostre treball amb metodologies ja utilitzades en l'àmbit de la recuperació d'informació musical, la classificació de gèneres i els sistemes de recomanació.

La recerca pot centrar-se en:

Ús de característiques acústiques com energia, tempo, danceability, valence, acousticness o loudness.

Aplicació de PCA, t-SNE o altres tècniques de reducció de dimensionalitat en datasets musicals.

Mètodes de clustering per agrupar cançons segons similitud musical.

Problemes habituals en la classificació per gènere, especialment quan una mateixa cançó pot encaixar en més d'una categoria.

Limitacions dels datasets basats en metadades i descriptors generats automàticament.

A l'informe, aquesta part hauria d'incloure una breu síntesi dels estudis consultats i explicar com ens ajuden a justificar l'enfocament triat.

3.4. Tasca 4

Finalment, cal discutir quines features del dataset s'utilitzen i per què. El dataset conté variables numèriques relacionades amb propietats musicals i acústiques, com popularity, acousticness, danceability, duration_min, energy, instrumentalness, liveness, loudness, speechiness, tempo i valence.

Per a cada variable, convé explicar-ne el significat i la possible rellevància. També cal justificar les variables que inicialment no s'han inclòs, com key, mode i time_signature. Aquestes variables són categòriques o musicals en un sentit diferent, i podrien requerir codificació específica abans d'entrar en models numèrics. Per tant, es poden deixar fora de la primera anàlisi i considerar-les com una possible extensió del projecte.

S'acaba la reunió a les 17:00.

Signatures:

A stylized signature consisting of a large, open 'G' shape with a horizontal line extending from the right side.

Elena Gutiérrez del Burgo

A signature starting with a large, circular 'C' followed by several loops and a horizontal line extending to the right.

Cristina Huanca

A signature featuring a large, stylized 'L' and 'C' intertwined, with a horizontal line extending from the right.

Laia Cámara

A signature that appears to be the name 'LAIA' written in a stylized, outlined font, with a large, circular flourish around it.

Laia Alcalde Maria

A signature starting with a large, stylized 'A' followed by several loops and a horizontal line extending to the right.

Alex Stefan Mayer

A signature that is a large, cloud-like or bubble-like shape with a scalloped edge.

Iker Bolancé Gómez