

ACTA DE REUNIÓ No. 4

22 MAIG 2026

ASSISTENTS: Laia Alcalde, Laia Cámara, Cristina Huanca, Elena Gutiérrez, Iker Bolancé i Alex Mayer

HORA D'INICI: 15:00

LLOC: Aula Q5/1012

1. Discussió.

En aquesta reunió de cierre es revisa l'estat final del projecte i es fixa la feina pendent fins a l'entrega del portfolio i la defensa oral. Totes les fases analítiques estan tancades: data massage (176.655 cançons netes, 11 features numèriques + 4 identificatives), EDA visual (7 figures + genre_profiles.csv + correlation_matrix.csv), PCA (scree + biplot + scatter per gènere; ~83% de variància acumulada amb 6 components), t-SNE (mostra de 10.000 cançons amb perplexity=40, semilla fixa 42), K-Means multi-k ($k \in \{3, 5, 7\}$, perfils i etiquetes humanes a config/cluster_profiles.json), xarxa de correlacions Plotly i dashboard Featurefy servit per API Flask (src/dashboard_api.py, 9 endpoints).

Es repassen els resultats per hipòtesi tal com es defensaran davant la professora:

- ➔ **H1 — Popularitat** ↔ features musicals. Cap feature explica per si sola la popularitat. Les correlacions principals són moderades: popularity vs acousticness = -0.35, vs loudness = +0.31, vs energy = +0.23, vs danceability = +0.21. Les cançons populars tendeixen a ser una mica menys acústiques i una mica més sonores/energètiques, però la relació no permet predicció forta ni causalitat.
- ➔ **H2 — Clusters acústics.** K-Means amb $k=3$ produeix tres perfils interpretables i ben dimensionats: C0 Spoken / Live (10.253 cançons) — speechiness i liveness molt alts; C1 Ambient / Instrumental (44.725 cançons) — alta acousticness i instrumentality, baixa energy/danceability; C2 Mainstream Pop / Rock (121.677 cançons) — alta energy, danceability, loudness i popularity. Els ids C0/C1/C2 són arbitraris: els noms humans viuen a config/cluster_profiles.json per no hardcodejar-los al HTML.
- ➔ **H3 — Diferències per gènere.** Hi ha perfils acústics diferenciats (Opera/Classical amb molta acousticness i poca energia; Comedy amb speechiness/liveness extrems; Reggaeton/Dance/Pop amb danceability i popularitat altes; Soundtrack amb molta instrumentality i poca valence) però amb solapament clar al PCA i al t-SNE. El gènere declarat no separa perfectament l'espai musical.

Es comenten les decisions metodològiques que el grup ha de saber defensar:

Deduplicació per track_id (-55.951 files de 232.725 a 176.774): evita que una mateixa cançó pesi diverses vegades en mètodes de distància i variància; el cost és perdre la relació multi-gènere, i així es reconeix com a limitació.

Filtrat de gèneres minoritaris: s'elimina A Capella (119 cançons) amb un llindar mínim de 1000 cançons per gènere; queden 26 gèneres.

No-clipping de duration_min (màxim 92,549 min, principalment Comedy/Soundtrack): el pipeline ho detecta i ho avisa amb [WARN], però no recorta perquè són cançons reals.

Estandardització amb StandardScaler abans de PCA/t-SNE/K-Means; el CSV net manté valors interpretables.

Correlacions redundants conegudes: energy ↔ loudness = +0.82 i energy ↔ acousticness = -0.73 — no es tracten com a independents al dashboard.

Sobre el dashboard Featurefy, es confirma que el navegador no recalcula res: l'API serveix CSV/JSON precalculats i dashboard/dashboard-boot.js fa el pont mapejant claus llargues a curtes i mutant window.DATA in-place. Regenerar t-SNE o K-Means només requereix re-executar l'script i reiniciar Flask.

Es tanca la discussió identificant els pendents reals: redactar l'informe/portfolio final seguint la plantilla Portfoli ProjecteVD -Template, preparar l'exposició oral amb el guió de 10 punts de la guia de validació i assajar les preguntes probables (apartats 15 i 19 de GUIA_VALIDACION_PORTFOLIO.md).

2. Acords.

- Tancar oficialment el pipeline analític. No es regeneren outputs llevat que es detecti un bug; els CSV/JSON a outputs/ i config/ queden congelats per a l'entrega.
- Repartir les seccions de l'informe final entre els 6 membres segons la taula 3.1 i fer una primera lectura conjunta el 29 maig 2026.
- Usar GUIA_VALIDACION_PORTFOLIO.md com a font canònica per a la redacció del portfolio: hipòtesis, resultats numèrics, frases de defensa i limitacions ja estan validats allà.
- Mantenir H1 / H2 / H3 com a fil narratiu de l'informe i de la defensa oral; cada visualització ha de quedar enllaçada amb la hipòtesi que ajuda a validar o matisar.
- Defensar explícitament com a limitacions reconegudes, no errors: deduplicació per track_id, no-clipping de duration_min, ús de Pearson com a primera aproximació, mostra de 10k per t-SNE, geometria esfèrica que imposa K-Means i etiquetes amb apòstrof diferents Children's Music / Children's Music.
- Preparar el guió oral de 10 punts, apartat 18 de la guia, i assajar el checklist final, apartat 19, abans de la defensa.
- Etiquetar el repositori amb una versió v1.0 un cop entregat l'informe.

Tasca	Descripció	Responsable	Participants (%)	Durada (setmanes)	Grau Finalització
Tasca 1	Dashboard v1 Featurefy	Laia A	Laia A (50%), Cris (50%)	2	100%
Tasca 2	Redacció informe	Elena	Elena (30%), Laia C (40%), Iker (30%)	1	100%
Tasca 3	Presentació	Alex	Tots	1	80%
GRAU DE MADURESA:					

3. Desenvolupament del projecte

3.1. Tasca 1

Dashboard v1 Featurefy

Descripció: Bundle interactiu generat amb Claude Design (dashboard/index.html) que consumeix els outputs del pipeline (EDA, PCA, t-SNE, K-Means, xarxa Plotly) a través de l'API Flask src/dashboard_api.py (9 endpoints) i el pont dashboard/dashboard-boot.js. Inclou les seccions Builder, Vinyl, Space (PCA/t-SNE amb slider $k=\{3,5,7\}$), Radar de gèneres i Graf de correlació. El navegador no recalcula res: només visualitza CSV/JSON precalculats.

3.2. Tasca 2

Redacció informe / portfolio final

Descripció: Seguint la plantilla Portfoli ProjecteVD -Template i la GUIA_VALIDACION_PORTFOLIO.md com a font canònica. Estructura: resum, introducció, dataset i data massage (176.655 cançons × 15 cols), metodologia (EDA / PCA / t-SNE / K-Means / Plotly), resultats per H1 (popularitat ↔ features), H2 (3 clusters acústics: Spoken-Live, Ambient-Instrumental, Mainstream Pop-Rock), H3 (perfils per gènere amb solapament), conclusions, limitacions i bibliografia.

3.3. Tasca 3

Preparació exposició oral

Descripció: Guió de 10 punts (apartat 18 de la guia de validació) que cobreix context, hipòtesis, neteja, EDA, correlacions clau (energy↔loudness +0.82), PCA, t-SNE, K-Means, dashboard/API i conclusions. Slides per a cada hipòtesi amb les figures defensables de outputs/, captures del dashboard i ronda de Q&A interna sobre les preguntes probables (apartat 15) i el checklist final (apartat 19).

S'acaba la reunió a les 19:00.

Signatures:

A stylized signature consisting of a large, open 'G' shape followed by a horizontal line.

Elena Gutiérrez del Burgo

A signature with a large, circular loop at the beginning, followed by several smaller loops and a horizontal line.

Cristina Huanca

A signature with a large, open 'C' shape followed by a horizontal line.

Laia Cámara

A signature with the word 'LAIA' written in capital letters, followed by a horizontal line.

Laia Alcalde Maria

A signature with a large, open 'A' shape followed by a horizontal line.

Alex Stefan Mayer

A signature that is a cloud-like shape with many small loops.

Iker Bolancé Gómez